

MANUAL DE USO DE BASE DE DATOS

Santiago, 06 de septiembre de 2024

1. ELEMENTOS GENERALES DEL ESTUDIO.

- a. **Nombre del estudio:** “Cambio climático y la socio-hidrología de las inundaciones”. Concurso Anillos de Investigación en Áreas Temáticas Específicas ANID – Año 2022
- b. **Objetivo:**
 - Analizar las interacciones de un clima cambiante, el ambiente fluvial y la sociedad en contexto de riesgo de daño por inundaciones.
- c. **Tipo de Encuesta:** PAPI (Entrevista Presencial Asistida por Papel), posteriormente digitada.
- d. **Universo:** Habitantes de zonas inundables de las comunas de San Pedro de Atacama, San Fernando, Hualqui y Arauco.
- e. **Muestra:**
 - Muestra semi-proporcional estratificada para una estimación de los habitantes en las zonas inundables en base a datos CENSO 2017.
- f. **Unidad de análisis:** Hogares en zonas inundables determinadas por el equipo de investigación en las comunas de San Pedro de Atacama, San Fernando, Hualqui y Arauco
- g. **Trabajo de campo:** Entre el 13 de junio de 2024 y el 17 de agosto de 2024.
- h. **Diseño muestral y levantamiento:** EKHOS.
- i. **Encuestas completas:** 1.007 encuestas válidas.
- j. **Error muestral:** +/- 5,9% para San Pedro de Atacama, +/- 5,0% San Fernando, Hualqui +/- 9,3% y +/-5,7% para Arauco.

Todos los errores consideran 95% de confianza y varianza máxima.

2. DESCRIPCIÓN GENERAL DE LA BASE DE DATOS:

- a. **Nombre de la Base:** BBDD_Socio-hidrología_2024.06.09
- b. **Diseño muestral:** EKHOS
- c. **Levantamiento:** EKHOS.
- d. **Última Modificación:** 06/09/2024
- e. **Tipo de datos:** Encuesta.
- f. **Formato de las bases de datos:** SPSS (.sav), Stata (.dat), R (.rds) Excel (.csv)

Cabe señalar que en terreno se aplicaron 1.015 encuestas en las cuatro comunas, pero que tras el proceso de revisión se invalidaron 8 casos bajo los siguientes criterios:

1. No contar con un medio de validación disponible, ni teléfono válido o correo electrónico.
2. Presentar errores en más de un módulo de la encuesta.

A continuación, en la Tabla N°1, se presenta el detalle de las encuestas realizadas, válidas e inválidas.

Tabla N°1: Resultados proceso de validación

Comuna	N° Encuestas Realizadas	N° Encuestas Válidas	N° Encuestas Inválidas
San Pedro de Atacama	254	252	2
San Fernando	383	380	3
Hualqui	102	100	2
Arauco	276	275	1
Total	1.015	1.007	8

3. DIMENSIONES DEL CUESTIONARIO:

Las dimensiones del cuestionario son 7:

1. **Caracterización del encuestado** (FOLIO hasta A2).
2. **Caracterización del hogar** (INTEGRANTES_HOGAR hasta B3_RELACION_10).
3. **Caracterización de la vivienda** (C4 hasta C13).
4. **Localidad de la red social** (C14_1 hasta C16_4).
5. **Experiencia según último episodio de inundación vivido** (D17 hasta D24).
6. **Percepción y conocimiento sobre riesgo de inundaciones** (E25 hasta E29_5).
7. **Redes de colaboración** (F30 hasta F35_5).
8. **Preparación ante eventos de inundación** (G36_1_1 hasta G39_1).
9. **Caracterización jefe/a de hogar** (H40 hasta I48).

4. TRATAMIENTO DE VALORES PERDIDOS¹.

En la presente base de datos se presentan distintos tipos de valores perdidos: a) No aplica, b) No Responde y c) No Sabe / No Responde o NS/NR.

a. No Aplica:

- Se utilizará el código 77 o 777.
- Se aplica en cada celda posterior a un filtro (En caso de que corresponda).

¹ Los criterios para asignar los códigos a las variables dependen de las encuestas utilizadas, por ejemplo, la Encuesta Social Europea (ESS) utiliza para los no aplica el código 6, 66 y 666. En el caso nacional, la ENE (Encuesta Nacional de Empleo) y las Encuestas Estadounidenses utilizan el valor 7, 77 o 777 para asignar el no aplica. No obstante, existe una tendencia a considerar 9, 99 o 999 a los valores asociados a No Responde y 8, 88 o 888 a los no sabe.

b. No Responde

- Se utilizará el código 99 para los "No Responde".

c. No sabe/No Responde:

- Se utilizará el código 98 y 998 para los "No sabe/No responde".

d. Otros

- Se utilizará el código 44 o 444.

Los formatos de cada uno de estos valores están determinados por la cantidad de categorías de respuesta que contenga una pregunta, es decir, si una pregunta posee atributos que consideran la alternativa 98, se utilizará 998 para "No sabe, No responde".

Siguiendo con la misma lógica, si existe una variable con categorías mayores o iguales a 77, se debe pasar al siguiente formato (777) para "No aplica".

Un ejemplo de la aplicación del "No aplica", ocurre en la variable C4_1 (*¿Su vivienda se encuentra pareada por ambos lados con otra vivienda, pareada solo por un lado o por ningún lado?*), si el encuestado no vive en casa, casa en cité, casa en pasaje o condominio cerrado, entonces se usa un "No aplica" para C4_1.

5. CODIFICACION DE VARIABLES

5.1. Preguntas cerradas

La codificación de las preguntas del cuestionario fue trabajada en similitud a lo expresado en distintas encuestas nacionales (EANNA y CASEN) e internacionales (ESS) donde se asocian números enteros consecutivos para identificar cada categoría de respuesta.

- Por ejemplo, la pregunta D24 posee 5 categorías para la pregunta **¿Cuán fuerte era el caudal del río en las inmediaciones de su hogar?** las cuales corresponden a "Muy bajo", "Bajo", "Ni bajo ni alto", "Alto" y "Muy alto", se les asigna valores del 1 al 5 respectivamente.
- Además se utilizan, en caso de ser necesarias, el valor 77 para las categorías de "No aplica", 98 en caso de que "No sabe/ No responde" y 99 si lo que corresponde es especificar solamente el "No responde".

5.2. Preguntas Abiertas

Las preguntas en las que se solicitan respuestas abiertas y espontáneas son registradas en forma literal por lo que requieren un tratamiento especial, dado que las respuestas entregadas por las personas contienen una amplia gama de alternativas de fraseos y respuestas.

Para esta entrega, EKHOS no realizó la codificación de las preguntas abiertas a la espera de la revisión de la base de datos y las respuestas literales por parte de la contraparte.

Una vez realizada la revisión y la entrega de lineamientos para la codificación, EKHOS podrá realizar la codificación a solicitud del mandante.

Cabe señalar que, habitualmente, se ocupa una estructura de codificación de tipo árbol, con niveles o ramas principales y secundarias, e incluso en algunos casos, terciarias. Y en el caso de la codificación más frecuente, se sigue una lógica de agrupación conceptual en dos niveles que permite generar una estructura lógica, en la que el primer nivel es un concepto general y el segundo nivel es una especificación de dicho concepto.

5.3. Respuesta “Otros”

Para el caso de preguntas con la categoría “Otros” en la que se da la posibilidad de especificar *¿Cuál?*, por lo que implican, por lo tanto, codificación. En este caso, se ocupa la lógica antes expuesta.

- Un ejemplo de esta situación es la pregunta D23_1 en el cuestionario donde se consulta respecto a quién emitió la alerta o aviso de evacuación en la última inundación, donde se logra asignar códigos a la mayoría de las respuestas.
- Aquellas que no son posibles de agrupar se les asigna el valor 44.

5.4. Codificación de Categoría Ocupacional (CIUO_08) y Actividad de la Empresa (CAENES)

Este proceso consiste en la codificación de las preguntas abiertas asociadas a la categoría ocupacional (variables H42 y H43) y Actividad principal de la empresa (H44).

Lo anterior se realiza utilizando un libro de códigos basado en CIUO-08 y CAENES, en base a respuestas de encuestas CASEN de años anteriores (específicamente se usó 2022), por lo que ya pasaron por un proceso de codificación y poseen un estándar de codificación internacional.

Con este libro de códigos se envía la base de datos a un codificador que asimila las respuestas de la base de datos con las de CASEN 2002. Una vez terminada esta “estandarización” de las respuestas a formato CASEN, ocurren 3 procesos:

Los codificadores encargados de estandarizar las respuestas tuvieron la instrucción de elegir la opción más adecuada para cada caso, donde fuera tan detallada como la respuesta original y en caso de no encontrar esa especificación, la elección debía ser la opción más general respecto a la respuesta original. O bien, dejar sin un pre-código si no existía similitud.

1. En primera instancia se codifican a códigos CIUO y CIU las respuestas estandarizadas que solo tienen un posible código CIUO/CIU, un ejemplo de este tipo de respuestas es “Abogado”.
2. Las respuestas estandarizadas que tienen más de un posible código CIUO/CIU, se mandan a un codificador, que debe zanjar el código usando una interfaz de codificación que entrega información adicional como la formalidad, nivel educación, ingreso y/o cantidad de personas a cargo.
3. Las respuestas estandarizadas sin código CIUO/CIU asociados, se envían a un codificador experto con experiencia INE/CASEN.

Luego de finalizado el proceso se logró codificar:

- > 705 de 711 casos del CIUO lo que equivale a un 99,1%.
- > Mientras que para el CIU se logró codificar 710 de 711 casos disponibles, lo que equivale a un 99,8% de éxito.

6. CREACIÓN DEL GSE

La creación del GSE se realizó considerando el proceso establecido por la Asociación de Investigadores de Mercado (AIM) en su versión 2023², el cual considera 4 variables:

1. Ingreso total del Hogar (H47 y H47_ALTERNATIVA).
2. Cantidad de miembros que componen el Hogar (INTEGRANTES_HOGAR).
3. Ocupación CIUO del jefe de hogar (CIUO_08_1N).
4. Nivel educacional del jefe de hogar (H46_1).

El proceso de codificación produce una variable de GSE (GSE_real) que se compone de 7 categorías: AB, C1a, C1b, C2, C3, D y E.

Cabe mencionar que alrededor de 94 casos no tenían valor para alguna de las variables claves usadas en la codificación, por lo que inicialmente no se les pudo asignar un GSE. Dichos casos se fueron a un arbitraje individual de caso 1 a 1 pareando las variables que si tenían valor.

7. USO DEL PONDERADOR

En primera instancia se creó ponderador trivariado con los datos censales de Tramos de edad, Comuna y Sexo de los encuestados. Con esta información se crea un ponderador para llevar los datos hacia los valores proporcionales que deberían observarse en la muestra si obedeciera la distribución porcentual observada en los datos censales:

De esta forma el factor de ponderación se refleja de la siguiente forma:

$$W_1 = \frac{P_{Npe1}}{P_{npe1}}$$

Donde P_{Npe1} representa la proporción del universo y P_{npe1} representa la proporción de la muestra obtenida, en torno al Tramo de edad, la Macrozona y el Sexo.

A continuación, se presenta la ponderación de cada uno de los segmentos a los que se busca representar.

² Para revisión de la construcción de la variable y su respectivo código, se puede revisar el manual de creación disponible en: <https://aimchile.cl/gse-chile/>

Tabla N°2: Universo, muestra y ponderación trivariada

Macrozona	Tramos de edad	Universo		Muestra		Ponderación	
		Hombre	Mujer	Hombre	Mujer	Hombre	Mujer
San Pedro de Atacama	Entre 18 y 29 años	15,0%	18,3%	14,3%	17,5%	1,05	1,05
	Entre 30 y 44 años	18,4%	18,9%	19,0%	18,7%	0,97	1,01
	Entre 45 y 59 años	9,6%	9,3%	9,1%	10,7%	1,05	0,87
	60 años o más	4,9%	5,5%	6,0%	4,8%	0,83	1,16
San Fernando	Entre 18 y 29 años	12,1%	11,0%	6,8%	5,0%	1,77	2,20
	Entre 30 y 44 años	14,3%	15,6%	13,2%	15,8%	1,09	0,99
	Entre 45 y 59 años	11,6%	13,2%	15,5%	15,5%	0,74	0,85
	60 años o más	9,6%	12,7%	13,7%	14,5%	0,70	0,87
Hualqui	Entre 18 y 29 años	11,2%	11,2%	13,0%	10,0%	0,86	1,12
	Entre 30 y 44 años	11,5%	11,7%	13,0%	18,0%	0,89	0,65
	Entre 45 y 59 años	13,7%	14,0%	12,0%	15,0%	1,14	0,93
	60 años o más	11,4%	15,3%	8,0%	11,0%	1,43	1,39
Arauco	Entre 18 y 29 años	11,9%	11,4%	10,9%	8,0%	1,09	1,42
	Entre 30 y 44 años	14,4%	15,1%	13,1%	16,0%	1,10	0,94
	Entre 45 y 59 años	12,9%	14,0%	14,9%	17,1%	0,86	0,82
	60 años o más	9,1%	11,3%	9,1%	10,9%	1,00	1,04

En términos del análisis hay que tener en consideración que se altera la frecuencia de los totales por ser la expansión de los valores poblacionales al usar la ponderación. Por lo que el n resultante de la ponderación difiere del n recolectado.

8. CONTACTO

Para solicitar el libro de códigos o cualquier información adicional, se recomienda escribir un correo electrónico a estudios@ekhos.cl